



UNIVERSIDADE DE
COIMBRA

FACULDADE
DE CIÊNCIAS
E TECNOLOGIA

Licenciatura em Engenharia Informática
Introdução à Inteligência Artificial
2019/2020 – 2º Semestre

D31: The Rise of the Ballz

<i>Diogo Jorge da Rocha Cota</i>	2017267601	uc2017267601@student.uc.pt	PL4
<i>João Filipe Carnide de Jesus Nunes</i>	2017247442	uc2017247442@student.uc.pt	PL4
<i>Raul Filipe Enes Nogueira</i>	2017267634	uc2017267634@student.uc.pt	PL4

Índice

Introdução	3
Objetivos Alcançados	3
Implementação	3
Experimentação	4
Mapa Evolving-ControlTheBallToAdversaryGoal	4
Testes de valores <i>default</i>	4
Testes de valores variáveis	5
Mapa Evolving-ControlTheBallToAdversayGoalRandom	8
Testes de valores <i>default</i>	9
Testes de valores variáveis	9
Mapa Evolving-Defense	10
Testes de valores <i>default</i>	10
Testes de valores variáveis	11
Mapa Evolving-DefenseRandom	12
Testes de valores <i>default</i>	12
Testes de valores variáveis	13
Mapa Evolving-OnevsOne	14
Testes de valores <i>default</i>	14
Testes de valores variáveis	14
Conclusões gerais das variações	16
Testes Iterativos	16
Agentes em ação	19
Conclusão	20
Referências	20

Introdução

Neste terceiro trabalho prático pretende-se fazer a implementação de um agente aprendiz que, através de um algoritmo genético, consiga, num certo ambiente, aprender a efetuar certas tarefas essenciais para a realização de um jogo de futebol, como defender, controlar a bola e marcar golo. Ou seja, pretende-se que o agente D31, ao longo de várias experimentações, altere de modo automático as suas estruturas internas, de modo a realizar melhor as tarefas pretendidas, nas condições impostas pelo ambiente.

Objetivos Alcançados

O objetivo deste trabalho prático foi a implementação de um Algoritmo Genético com base nas funcionalidades básicas que caracterizam este algoritmo: recombinação, mutação, seleção, parametrização e aptidão. Os Algoritmos Genéticos são algoritmos de otimização global, baseados em mecanismos de seleção natural e de genética. Estes algoritmos empregam uma estratégia de busca paralela e estruturada, mas aleatória, que é voltada em direção ao reforço da busca de pontos que apresentem uma alta aptidão, ou seja, pontos nos quais a função a ser maximizada (no caso deste trabalho prático) tem valores relativamente altos.

Implementação

Na recombinação foi implementada uma função de *crossover* que apresenta apenas um ponto de corte aleatório nos cromossomas pai onde, através desse corte, irá resultar na troca dos dados entre os dois progenitores após o ponto de corte.




Figura 1 – Recombinação num ponto

No que diz respeito à mutação foi implementado uma função de mutação gaussiana que recebe uma probabilidade de ocorrer mutação. Caso esta probabilidade seja baixa previne que uma certa posição fique estagnada num valor, caso a probabilidade seja alta a busca tornar-se-á essencialmente aleatória.

Na seleção foi desenvolvido uma função de seleção por torneio, esta função de maximização permite selecionar o melhor indivíduo num torneio de certo tamanho.

No que diz respeito à função de aptidão, tendo em conta todas as informações que estão disponíveis, esta foi inicialmente desenvolvida com base nas seguintes informações: *distanceTravelled*; *hitTheBall*; *hitTheWall*; *GoalsOnMyGoal*; *GoalsOnAdversaryGoal*. Nesta função o fitness do agente será premiado pela distância percorrida, pelas vezes que tocar na bola (posse de bola) e pelos golos marcados na baliza do adversário. Caso o agente bata nas paredes ou sofra um golo será penalizado, de modo a evitar que, no

processo de aprendizagem, o agente bata nas paredes e saiba que deve proteger a sua baliza.

Experimentação

Na parte da experimentação, mediante às funções de aptidão foi desenvolvida uma diferente função de *fitness* para cada um dos mapas. No que diz respeito à variação de valores em cada um dos mapas foram variados os valores da probabilidade de mutação, probabilidade de recombinação, a existência de elitismo e o tamanho do torneio individualmente, mantendo os outros valores como *default*, como se pode observar na seguinte tabela dos valores *default*.

Tamanho População	20
Tamanho Torneio	3
Probabilidade Mutação Vermelho	0.02
Probabilidade Crossover Vermelho	0.9
Elitismo Vermelho	Sim
Probabilidade Mutação Azul	0.02
Probabilidade Crossover Azul	0.9
Elitismo Azul	Sim

Ver em anexo gráficos de todos os testes presentes neste relatório, os mais significativos também estão presentes ao longo deste relatório.

Mapa Evolving-ControlTheBallToAdversaryGoal

Neste mapa, em que o objetivo é o agente marcar golo com a bola que se encontra no meio campo, a função de aptidão foi desenvolvida tendo em conta os golos marcados, vezes que o agente tocou na bola, golos sofridos e vezes que o agente bateu na parede, sendo penalizado nestes últimos dois casos e beneficiado nos outros dois.

$$\begin{aligned} fitness &= \text{golosMarcados} + \text{pntsPosseBola} - \text{golosSofridos} - \text{pntsBaterParede} \\ \text{golosMarcados} &= \text{GoalsOnAdversaryGoal} * 10000 \\ \text{pntsPosseBola} &= \text{hitTheBall} * 100 \\ \text{golosSofridos} &= \text{GoalsOnMyGoal} * 10000 \\ \text{pntsBaterParede} &= \text{hitTheWall} * 100 \end{aligned}$$

Mediante os **testes dos valores *default*** foram efetuados três testes, cada um destes com 300 gerações. A partir destes testes foi calculada a média e o desvio padrão da média do *fitness* população do agente ao fim das 300 gerações (PopAvgRed) bem como a média e o desvio padrão do melhor *fitness* encontrado em cada um dos testes (BestOverallRed). Sabendo, de seguida, qual dos testes apresenta o melhor valor de *fitness* (sublinhado a verde na tabela seguinte), será feito um teste iterativo sobre este agente no mapa seguinte (mapa de controlo de bola para a baliza adversária com a bola numa posição aleatória) para se verificar o seu comportamento e como, ao longo das gerações, ocorre a variação da sua função de aptidão. Isto foi aplicado da mesma forma para os restantes mapas.

	PopAvgRed	BestOverallRed
Teste 1	92900	106400
Teste 2	93575	107200
Teste 3	84270	106300
Média Testes	90248,33333	106633,3333
Desvio Padrão	5188,377235	493,2882862

Com esta tabela podemos verificar que o melhor teste realizado foi o Teste 2, no próximo mapa irá ser posto à prova este teste de forma a verificar como se comporta, tento já um dado valor de *fitness*. Outras conclusões que podemos tirar da análise dos resultados obtidos é que a função de aptidão se adequa ao ambiente visto que, ao longo das gerações, o agente consegue realizar os seus objetivos pretendidos (controlar a bola à baliza adversária e marcar golo).

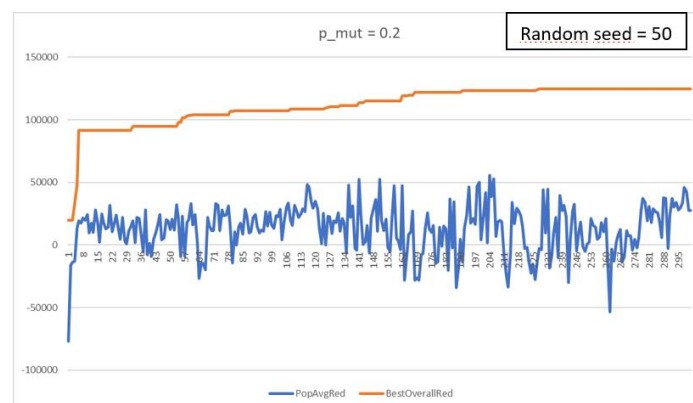
Passando agora aos testes de variação de certos valores.



Este mapa foi o mapa escolhido para fazer a verificação e respetiva validação de quais os melhores valores para cada parâmetro do algoritmo genético, onde foram feitos vários testes para o mesmo valor com *random seed* variável e, a partir daí, chegar à conclusão se os valores *default* que foram utilizados foram realmente os mais acertados.

Probabilidade de mutação

Para este mapa e para os seguintes foram testados vários valores de probabilidade de mutação, para se verificar qual o valor ideal para esta probabilidade.

	PopAvgRed	BestOverallRed
Prob. Mut. = 0.2 Random seed = 10	37110	116000
Prob. Mut. = 0.2 Random seed = 25	50790	117300
Prob. Mut. = 0.2 Random seed = 50	27340	124700
Prob. Mut. = 0.9 Random seed = 10	-27140	109900
Prob. Mut. = 0.9 Random seed = 25	4435	117100
Prob. Mut. = 0.9 Random seed = 50	-17775	102000








Com a análise da tabela e dos gráficos conseguimos concluir que o melhor valor de probabilidade de mutação será o valor mais baixo, pois quando mais baixa esta probabilidade, menos aleatório se tornará, como podemos verificar com o valor médio da população quando a probabilidade de mutação é 0.02, onde estes valores médios estão sempre muito perto do valor do melhor agente encontrado em cada geração. Quando o valor da probabilidade é alto, a média é sempre baixa, raramente com valores positivos.

Probabilidade de recombinação

Para todos os mapas foi ainda variada a probabilidade de recombinação de modo a concluir se os valores *default* são os ideais

	PopAvgRed	BestOverallRed
Prob. Rec. = 0.05 Random seed = 10	48480	76000
Prob. Rec. = 0.05 Random seed = 25	99400	112800
Prob. Rec. = 0.05 Random seed = 50	83310	103000
Prob. Rec. = 0.5 Random seed = 10	82980	99000
Prob. Rec. = 0.5 Random seed = 25	96415	108700
Prob. Rec. = 0.5 Random seed = 50	87120	113000







O que podemos observar a partir da tabela e dos gráficos dos diferentes valores de probabilidade de recombinação é que o melhor valor será quando teremos uma probabilidade mais alta pois, a partir daqui temos valores da média mais concisos, apesar dos valores do melhor agente serem aproximadamente semelhantes, temos uma média da população média muito melhor quando o valor da probabilidade de *crossover* é mais alto, 0.9.

Elitismo

Para verificar o comportamento do agente foi desativado o elitismo para verificar qual a melhor opção para o algoritmo genético.

	PopAvgRed	BestOverallRed
Sem Elitismo Random seed = 10	62875	95700
Sem Elitismo Random seed = 25	86705	109100
Sem Elitismo Random seed = 50	75075	107100





As conclusões que tiramos deste mapa quando o agente é elitista ou não são que os melhores valores são apresentados quando o agente é elitista, pois é preservada o melhor indivíduo para a próxima geração. Quando não é transferido o melhor valor para

a geração seguinte, nota-se um declínio na população média, como se pode observar nos gráficos e na tabela.

Tamanho do torneio

Foi testado também um valor de tamanho de torneio mais próximo do tamanho total da população para se verificar se é melhor um valor alto ou baixo.

	PopAvgRed	BestOverallRed
Tam. Torneio = 15 Random seed = 10	52465	102300
Tam. Torneio = 15 Random seed = 25	77090	108500
Tam. Torneio = 15 Random seed = 50	83220	110100



Com um tamanho de torneio maior podemos verificar que os resultados são piores pois os indivíduos mais fracos não são selecionados o que torna a média da população mais baixa, como podemos ver no gráfico do tamanho de torneio 15, onde o melhor valor de *fitness* foi 0 até sensivelmente metade das gerações.

Mapa Evolving-ControlTheBallToAdversaryGoalRandom

Neste mapa o objetivo é semelhante ao do mapa anterior, marcar gol na baliza adversária, contudo neste mapa a bola encontra-se numa posição aleatória. Graças a este fator a função de *fitness* teve de ter mais alguns aspetos em consideração do que os golos marcados e sofridos e bater na bola ou nas paredes como a distância do agente à bola e a distância do agente à baliza adversária

$$\begin{aligned}
 fitness &= \text{golosMarcados} + \text{pntsPosseBola} - \text{golosSofridos} - \text{pntsBaterParede} \\
 &\quad - \text{distanciaBola} - \text{distanciaBalizaAd} \\
 \text{golosMarcados} &= \text{GoalsOnAdversaryGoal} * 10000 \\
 \text{pntsPosseBola} &= \text{hitTheBall} * 100 \\
 \text{golosSofridos} &= \text{GoalsOnMyGoal} * 10000 \\
 \text{pntsBaterParede} &= \text{hitTheWall} * 100 \\
 \text{distanciaBola} &= \text{média}(\text{distanceToBall}) * 2 \\
 \text{distanciaBalizaAd} &= \text{média}(\text{distanceToAdversaryGoal}) * 5
 \end{aligned}$$

Teste *default*

	PopAvgRed	BestOverallRed
Teste 1	-2071	75099
Teste 2	-5121	74699
Teste 3	-1	79599
Média Testes	-2397,666667	76465,66667
Desvio Padrão	2575,584076	2720,906712

Antes da análise deste teste esperava-se resultados não tão bons como os de ControlBall, pois este mapa é mais complexo devido à posição da bola estar sempre a variar.

Estudando os resultados obtidos para os valores de PopBestRed, PopAvgRed, BestOverallRed conseguimos obter os resultados esperados, e concluímos que para obter resultados tão bons como os de ControlBall teríamos de aumentar o número de gerações.

Passando agora aos testes de variação de certos valores.

Probabilidade de mutação

	PopAvgRed	BestOverallRed
Prob. Mut. = 0.02	-1	79599
Prob. Mut. = 0.2	1308,719	116599,1
Prob. Mut. = 0.9	-58187,1	92498,04

Para o estudo deste caso sabemos que diminuindo a probabilidade de mutação podemos obter melhores resultados do que quando a probabilidade de mutação é mais alta, pois quanto mais baixa for a probabilidade de mutação menos aleatório será o teste, ou seja, este em ambos os casos devemos ter resultados piores do que quando a probabilidade de mutação é *default*.

Analisando os resultados obtidos, conclui-se que obtivemos resultados para a PopBestRed, PopAvgRed, BestOverallRed melhores do que nas circunstâncias iniciais, mas analisando os gráficos e as médias de cada caso temos valores piores que quando a probabilidade de mutação é igual a 0.02 (*default*).

Probabilidade de recombinação

	PopAvgRed	BestOverallRed
Prob. Rec. = 0.9	-1	79599
Prob. Rec. = 0.05	-3361,313	98198,32
Prob. Rec. = 0.5	-3361,313	90898,41

Ao contrário da variação da probabilidade de mutação, a probabilidade de crossover quanto mais baixa for deverá retornar valores piores, pois quanto mais alta for mais cromossomas serão cruzados na geração seguinte.

Analisando os resultados obtidos para PopBestRed, PopAvgRed, BestOverallRed verificamos que estes são melhores do que quando a probabilidade de crossover é 0.9 (*default*), mas analisando os gráficos e as médias de cada um concluímos que as condições iniciais obtêm melhores resultados.

Elitismo

	PopAvgRed	BestOverallRed
Com Elitismo	-1	79599
Sem Elitismo	-11751	68798,55

Neste caso e analisando os resultados obtidos para PopBestRed, PopAvgRed, BestOverallRed podemos concluir que estes são piores do que os resultados obtidos do que os resultados nas condições iniciais. Isto deve-se ao facto de o elitismo preservar os melhores agentes de uma geração para a geração seguinte, ou seja, retirando o elitismo não haverá passagem do melhor agente o que irá afetar os valores.

Tamanho do torneio

	PopAvgRed	BestOverallRed
Tam. Torneio = 3	-1	79599
Tam. Torneio = 15	-23290,85	73998,45

Observando os resultados obtidos, num teste com o tamanho do torneio igual a 15, podemos concluir que obtivemos resultados mais baixos para PopBestRed, PopAvgRed, BestOverallRed e o mesmo se aplica observando o seu gráfico pois em média os valores são mais baixos do que em condições iniciais. Isto ocorre devido aos indivíduos mais fracos não serem selecionados o que torna a média da população mais baixa.

Mapa Evolving-Defense

Neste mapa o objetivo que se pretende o agente realizar é defender a bola, que se encontra em movimento em direção à sua baliza. A função de aptidão que foi desenvolvida neste mapa teve em conta os fatores recorrentes como os golos marcados e sofridos e bater na bola ou nas paredes, mas também a distância da bola à baliza do agente.

$$fitness = golosMarcados + pntsPosseBola + defesaBola - golosSofridos - pntsBaterParedes$$

$$golosMarcados = GoalsOnAdversaryGoal * 10000$$

$$pntsPosseBola = hitTheBall * 100$$

$$defesaBola = média(distancefromBallToMyGoal) * 5$$

$$golosSofridos = GoalsOnMyGoal * 10000$$

$$pntsBaterParede = hitTheWall * 100$$

Teste default

	PopAvgRed	BestOverallRed
Teste 1	-107039,7	-89899,66
Teste 2	-27494,21	3401,66
Teste 3	-7264,439	46100,79
Média Testes	-47266,11633	-13465,94667
Desvio Padrão	52744,40147	69551,4326

Numa primeira análise, os resultados para média de pontos de PopBestRed, PopAvgRed e BestOverallRed não foram muito promissores, por apresentarem todos uma

média negativa de, aproximadamente, -12499.99, -47266.12, -13465.95, respetivamente. Estes valores de *fitness* são baixos pois a bola vai em direção à baliza do agente com uma velocidade tão grande que o agente tem muitas dificuldades em defender a bola, tornado estes mapas de defesa ligeiramente ingratos para o desenvolvimento do *fitness* dos agentes.

Passando agora aos testes de variação de certos valores.

Probabilidade de mutação

	PopAvgRed	BestOverallRed
Prob. Mut. = 0.02	-7264,439	46100,79
Prob. Mut. = 0.2	-29014.56	1100.56
Prob. Mut. = 0.9	-38884.72	115900.6

Os resultados foram os esperados, pois sabia-se à partida que quanto menor fosse a probabilidade de mutação, menor seria a aleatoriedade do comportamento do agente. Podemos observar este facto quando se obteve o valor de PopAvgRed (-38884.72), quando a probabilidade de mutação era de 0.9, ou seja, mais baixo que os valores *default*, no qual esta probabilidade era de 0.02.

Probabilidade de recombinação

	PopAvgRed	BestOverallRed
Prob. Rec. = 0.9	-7264,439	46100,79
Prob. Rec. = 0.05	-9406.901	298.1492
Prob. Rec. = 0.5	-109844.6	-109699.6

À partida sabe-se que quanto maior a probabilidade de *crossover*, mais cromossomas serão cruzados na geração seguinte. Analisando os gráficos e as tabelas, verifica-se que nos testes *default*, onde foi usada uma probabilidade de *crossover* de 0.9, os resultados obtidos são melhores do que os resultados atingidos pelos testes de *crossover* quando as probabilidades são de 0.05 e 0.5.

Elitismo

	PopAvgRed	BestOverallRed
Com Elitismo	-7264,439	46100,79
Sem Elitismo	-18195.04	46700.82

O elitismo preserva os melhores resultados de geração em geração. E, de facto, nos testes onde o elitismo foi preservado, os resultados foram, em média, melhores do que os resultados obtidos quando o elitismo é desprezado.

Analisando o gráfico do teste onde o elitismo é desprezado neste mapa, conseguimos observar que nas primeiras gerações os resultados de *fitness* são sempre menores que -100000.

Tamanho do torneio

	PopAvgRed	BestOverallRed
Tam. Torneio = 3	-7264,439	46100,79
Tam. Torneio = 15	-110934.6	-109699.5

Ao aumentar o tamanho do torneio, verifica-se que os resultados são piores, visto que, os indivíduos mais fracos afetam a média da população, tornando-a mais baixa.

De facto, analisando o gráfico deste mapa onde o tamanho do torneio é 15, pode-se observar que os valores de *fitness* da PopAvgRed e BestOverallRed mantiveram-se sempre abaixo de -100000.

Mapa Evolving-DefenseBallRandom

Neste mapa o objetivo é o mesmo que o mapa anterior, defender a bola e prevenir que esta entre na baliza do agente, contudo, desta vez, a bola está a ser direcionada para a baliza de uma posição aleatória a cada geração, o que torna o processo de aprendizagem do agente muito mais difícil. Para isto, foi desenvolvida uma função de *fitness* com base nos golos marcados e sofridos, em bater na bola ou nas paredes bem como a distância da bola à baliza do agente, a distância da bola ao agente e a distância do agente à sua baliza.

$$\begin{aligned} fitness &= \text{golosMarcados} + \text{pntsPosseBola} + \text{defesaBola} - \text{golosSofridos} \\ &\quad - \text{pntsBaterParede} - \text{distanciaBaliza} - \text{distanciaBola} \\ \text{golosMarcados} &= \text{GoalsOnAdversaryGoal} * 10000 \\ \text{pntsPosseBola} &= \text{hitTheBall} * 100 \\ \text{defesaBola} &= \text{média}(\text{distancefromBallToMyGoal}) * 5 \\ \text{golosSofridos} &= \text{GoalsOnMyGoal} * 10000 \\ \text{pntsBaterParede} &= \text{hitTheWall} * 100 \\ \text{distanciaBaliza} &= \text{média}(\text{distanceToMyGoal}) * 5 \\ \text{distanciaBola} &= \text{média}(\text{distanceToBall}) * 2 \end{aligned}$$

Teste default

	PopAvgRed	BestOverallRed
Teste 1	-96999	35101
Teste 2	-102839	7700
Teste 3	-97284	-37199
Média Testes	-99040,66667	1867,333333
Desvio Padrão	3292,538281	36501,19862

Antes de serem feitos os testes existia a noção de que dificilmente conseguiríamos obter resultados tão bons quanto os que obtivemos no mapa Evolving-Defense, por neste mapa a bola estar a variar de posição.

Estudando os resultados obtidos para os valores de PopBestRed, PopAvgRed, BestOverallRed conseguimos obter os resultados esperados, e concluímos que para obter resultados tão bons como os de Evolving-Defense teríamos de aumentar o número de gerações.

Passando agora aos testes de variação de certos valores.

Probabilidade de mutação

	PopAvgRed	BestOverallRed
Prob. Mut. = 0.02	-96999	35101
Prob. Mut. = 0.2	-95244,5	-52301,3
Prob. Mut. = 0.9	-91264,9	16799,79

Analisando os resultados após a variação da probabilidade de mutação obtivemos resultados para PopBestRed, PopAvgRed, BestOverallRed piores aos das condições iniciais, e até mesmo analisando os gráficos concluímos que nas condições iniciais conseguimos obter uma melhor média, e isto deve-se ao facto de quanto mais baixa for a probabilidade de mutação menos aleatório será o teste.

Probabilidade de recombinação

	PopAvgRed	BestOverallRed
Prob. Rec. = 0.9	-96999	35101
Prob. Rec. = 0.05	-89727,5	-66703,47
Prob. Rec. = 0.5	-123148,3	-19702,78

Diminuindo a probabilidade de crossover espera-se que os resultados sejam piores do que nas condições iniciais, devido ao facto de, quando se baixa a probabilidade, diminuir o número de cromossomas que serão cruzados na geração seguinte.

Analisando os resultados obtidos notamos que estes são piores do que os resultados em condições iniciais, tal como os valores das suas médias, como seria esperado.

Elitismo

	PopAvgRed	BestOverallRed
Com Elitismo	-96999	35101
Sem Elitismo	-91729,4	-79399,3

O elitismo preserva os melhores agentes de uma geração para a seguinte, sem o elitismo espera-se obter piores valores de fitness, pois não é feita a passagem dos melhores agentes.

Analisando os resultados para PopBestRed, PopAvgRed, BestOverallRed, tal como os seus gráficos, obtivemos, tal como seria esperado, piores resultados do que com elitismo, logo podemos concluir o que se previa antes da análise dos resultados, que um teste com uso de elitismo pode obter melhores resultados do que um teste sem uso do mesmo.

Tamanho do torneio

	PopAvgRed	BestOverallRed
Tam. Torneio = 3	-96999	35101
Tam. Torneio = 15	-100132,8	15398,69

Alterando o valor de tamanho do torneio para um valor superior ao inicial podemos esperar obter piores resultados devido aos indivíduos mais fracos não serem selecionados o que torna a média da população mais baixa.

Analisando os resultados obtidos podemos concluir o esperado, pois nota-se que os melhores de PopBestRed, PopAvgRed, BestOverallRed são mais baixos do que os obtidos com as condições iniciais, tal como acontece com os gráficos de ambos os casos.

Mapa Evolving-OnevsOne

O objetivo deste mapa é colocar dois agentes independentes um contra o outro, cada um com o objetivo de marcar gol na baliza do adversário e, ao mesmo tempo, tentar proteger a sua baliza, de modo a não sofrer golos. A função de aptidão que se teve em conta neste mapa teve como parâmetros os golos marcados e sofridos, o bater na bola ou nas paredes, a distância do agente à bola, a distância do agente à baliza adversária, a distância da bola à baliza adversária e a distância da bola à baliza do próprio agente. Para termos de comparação de comportamento foi implementado a mesma função de *fitness* para os dois agentes.

$$\begin{aligned} fitness &= \text{golosMarcados} + \text{pntsPosseBola} - \text{golosSofridos} - \text{pntsBaterParede} \\ &\quad - \text{distanciaBola} - \text{distanciaBalizaAd} - \text{remateBola} + \text{defesaBola} \\ \text{golosMarcados} &= \text{GoalsOnAdversaryGoal} * 10000 \\ \text{pntsPosseBola} &= \text{hitTheBall} * 100 \\ \text{golosSofridos} &= \text{GoalsOnMyGoal} * 10000 \\ \text{pntsBaterParede} &= \text{hitTheWall} * 100 \\ \text{distanciaBola} &= \text{média}(\text{distanceToBall}) * 2 \\ \text{distanciaBalizaAd} &= \text{média}(\text{distanceToAdversaryGoal}) * 5 \\ \text{remateBola} &= \text{média}(\text{distancefromBallToAdversaryGoal}) * 5 \\ \text{defesaBola} &= \text{média}(\text{distancefromBallToMyGoal}) * 5 \end{aligned}$$

Teste default

	PopAvgRed	PopAvgBlue	BestOverallRed	BestOverallBlue
Teste 1	42375,88	79450,02	103295,3	124000,5
Teste 2	50995,88	63274,98	107896,6	122400,3
Teste 3	59798,62	33988,15	94999,23	90597,77
Teste 4	69745,86	98090	101097	120300,4
Média Testes	55729,06	68700,7875	101822,0325	114324,7425
Desvio Padrão	11743,68497	27164,1823	5358,70611	15890,38093

Os resultados que tiramos da análise dos testes é que, em média, ambos os agentes obtiveram bons resultados, sendo o agente Azul o qual alcançou os melhores valores de *fitness* para PopAvg e BestOverall, portanto, 27164.18 e 15890.38, respetivamente.

Passando agora aos testes de variação de certos valores.

Probabilidade de mutação

	PopAvgRed	PopAvgBlue	BestOverallRed	BestOverallBlue
Prob. Mut. = 0.02	50995,88	63274,98	107896,6	122400,3
Prob. Mut. = 0.2	17267,6	4362,655	105196,9	101599,9
Prob. Mut. = 0.9	15137,61	21712,43	77497,31	98398,94

Os resultados foram os esperados, pois sabia-se à partida que quanto menor fosse a probabilidade de mutação, menor seria a aleatoriedade do comportamento dos agentes. Podemos observar este facto quando se obteve o valor de PopAvgRed (15137.61) e PopAvgBlue (21712.43), quando a probabilidade de mutação era de 0.9, ou seja, mais baixo que os valores *default*, no qual esta probabilidade era de 0.02.

Probabilidade de recombinação

	PopAvgRed	PopAvgBlue	BestOverallRed	BestOverallBlue
Prob. Rec. = 0.9	50995,88	63274,98	107896,6	122400,3
Prob. Rec. = 0.05	64048.61	49036.93	86999.23	79598.09
Prob. Rec. = 0.5	80341.21	92300.02	108996.3	117400.4

À partida sabe-se que quanto maior a probabilidade de *crossover*, mais cromossomas serão cruzados na geração seguinte. Analisando os gráficos e as tabelas, verifica-se que nos testes *default*, onde foi usada uma probabilidade de *crossover* de 0.9, os resultados obtidos são melhores do que os resultados atingidos pelos testes de *crossover* quando as probabilidades são de 0.05 e 0.5.

Elitismo

	PopAvgRed	PopAvgBlue	BestOverallRed	BestOverallBlue
Com Elitismo	50995,88	63274,98	107896,6	122400,3
Sem Elitismo	-9033,23	46764,53	108696,9	116999,9

O elitismo preserva os melhores resultados de geração em geração. E, de facto, nos testes onde o elitismo foi preservado, os resultados foram, em média, melhores do que os resultados obtidos quando o elitismo é desprezado.

Analisando o gráfico do teste onde o elitismo é desprezado neste mapa, podemos observar que nas primeiras gerações, apenas o valor de BestOverallBlue se mantém acima do patamar dos 50000 “pontos” de *fitness*, enquanto seria de esperar que, tal como nos testes *default*, onde o elitismo é mantido, esse patamar seja alcançado, também pelo BestOverallRed.

Tamanho do torneio

	PopAvgRed	PopAvgBlue	BestOverallRed	BestOverallBlue
Tam. Torneio = 3	50995,88	63274,98	107896,6	122400,3
Tam. Torneio = 15	55936.2	94034.71	80595.78	109699.8

Ao aumentar o tamanho do torneio, verifica-se que os resultados são piores, visto que, os indivíduos mais fracos afetam a média da população, tornando-a mais baixa.

De facto, analisando o gráfico deste mapa onde o tamanho do torneio é 15, pode-se observar que os valores de *fitness* da PopAvgRed, BestOverallRed, PopAvgBlue e BestOverallBlue, foram, em média, mais baixos do que os valores *default*.

Conclusões gerais das variações

Probabilidade de mutação

A conclusão que tiramos em relação à probabilidade de mutação é que deve ser um valor baixo (não mais que 5%) pois, como foi visto nos diferentes mapas, uma probabilidade de mutação alta torna os resultados mais aleatórios no que diz respeito ao *fitness* de uma população.

Probabilidade de recombinação

Quanto à probabilidade de recombinação, concluímos que esta deve ter um valor alto (mais de 75%) pois ajuda a explorar mais o espaço da solução e oferece ao algoritmo genético uma capacidade de pesquisa global.

Elitismo

Quanto ao elitismo chegamos à conclusão de se obtêm melhores resultados caso o agente seja elitista, pois este passa o melhor valor de *fitness* de uma geração diretamente para a geração seguinte.

Tamanho do torneio

No que diz respeito ao tamanho do torneio este deve ser mantido baixo, em relação ao tamanho total da população, pois existe uma boa hipótese de todos os indivíduos serem selecionados, sendo preservada a diversidade, com uma redução de convergência. Quando o valor do tamanho do torneio é alto, os indivíduos mais fracos têm uma probabilidade baixa de serem selecionados, reduzindo assim a diversidade e acelerando a convergência, pois os indivíduos da geração serão somente os melhores.

Outros valores que poderiam ser variados

Outros valores que poderiam ter sido variados seriam o número de nós presentes na camada escondida da rede neuronal onde um maior número de nós faria provavelmente que fosse mais provável um indivíduo sofrer mutação, pois este operador atua sobre cada nó desta camada. Um outro parâmetro que poderia ser variado seria o tamanho da população que estará relacionado com o número de gerações, pois uma população maior necessitará de mais tempo para evoluir do que uma população mais pequena, onde não serão necessárias tantas gerações.

Testes Iterativos

Os testes iterativos dizem respeito ao treino do mesmo agente em mapas diferentes para observação do seu comportamento ao longo dos mapas. Para isto foram encontrados os melhores testes para diferentes mapas (ControlBall e Defense) e a partir daí treinados noutros mapas.




Agente AndreSilva

Este agente foi iniciado no mapa ControlBall onde apresenta o seu *fitness* será igual ao melhor resultado encontrado neste mapa. De seguida foi testado no mapa

ControlBallRandom e finalmente no OnevsOne, contra um agente que apresentava *fitness* inicial de 0 (agente azul nos gráficos).

A tabela e os gráficos seguintes mostram os diferentes valores de *fitness* do agente nos diferentes mapas testados.

	PopAvgRed	BestOverallRed
ControlBall	93575	107200
ControlBallRandom	-10940.8	81698.3
OnevsOne	10483.4	77297.22




Agente Haaland

Este agente apresentou os mesmos testes com os mesmos valores do agente anterior, contudo ainda foi testado mais uma vez no mapa OnevsOne mas desta vez com a sua posição e a posição da bola aleatórias em cada geração durante 500 gerações, mais uma vez contra um agente com *fitness* inicialmente a 0 (agente azul nos gráficos).

A tabela e o gráfico seguinte mostram os diferentes valores de *fitness* do agente nos diferentes mapas testados.

	PopAvgRed	BestOverallRed
ControlBall	93575	107200
ControlBallRandom	-10940.8	81698.3
OnevsOne	10483.4	77297.22
OnevsOneRandom	-1.05648	50899.35





Agente Patrício

Este agente foi iniciado no mapa Defense onde apresenta o seu *fitness* será igual ao melhor resultado encontrado neste mapa. De seguida foi testado no mapa DefenseRandom e finalmente no OnevsOne, contra um agente que apresentava *fitness* inicial de 0 (agente azul nos gráficos).

A tabela e os gráficos seguintes mostram os diferentes valores de *fitness* do agente nos diferentes mapas testados.

	PopAvgRed	BestOverallRed
Defense	-7264,439	46100,79
DefenseRandom	-23040.97	16898.65
OnevsOne	64900.5	84700.52





Agentes em ação

Os agentes desenvolvidos iterativamente foram de seguida postos à prova no mapa MatchMaker para ver os seus comportamentos uns contra os outros para um jogo de 1 minuto. Na tabela seguinte estão as diferentes combinações de jogos que foram feitos, apresentando o seu valor de *fitness* e o resultado ao fim dos 60 segundos. O agente Static é um agente que não tem qual quer ficheiro de input.

	Resultado	<i>Fitness</i>
Static vs AndreSilva	0 – 2	-3,78249 14898,67
Static vs Haaland	0 – 0	-3,189474 -85602,48
Static vs Patricio	0 – 1	-4,43113 10699,75
AndreSilva vs AndreSilva	0 – 0	-92700,79 -199294,3
AndreSilva vs Haaland	1 - 0	4999,003 -526005,6
AndreSilva vs Patricio	0 – 0	-23001,25 -154104,5
Haaland vs Haaland	0 – 0	-82802,44 -516604,4
Haaland vs Patricio	0 – 0	-47901,86 -12001,78
Patricio vs Patricio	1 – 0	10299,36 -54302,5

Conclusão

Em conclusão, este trabalho prático permitiu a implementação e experimentação de um algoritmo genético com base nas funcionalidades do algoritmo (mutação, recombinação, seleção, parametrização e aptidão) para desenvolver um agente capaz de, ao longo do tempo, aprender a resolver certas tarefas, no nosso caso, marcar golos, ter posse de bola e defender a sua baliza.

A conclusão que se tirou com a experimentação foi que existem melhores valores para certas funcionalidades do algoritmo genético, como dever apresentar uma probabilidade de mutação baixa, uma probabilidade de recombinação alta, uma seleção baixa relativamente ao tamanho da população. Quando à aptidão (*fitness*) concluímos que esta estará diretamente dependente dos parâmetros que receberá, como, no exemplo deste trabalho, os golos marcados e sofridos, o agente bater na bola ou nas paredes, *etc.*

Finalmente, entendemos que os objetivos pretendidos com este trabalho práticos foram cumpridos, pois o grupo obteve competências no que diz respeito à implementação, experimentação e análise dos resultados das redes neuronais com o algoritmo genético.

Este trabalho prático foi uma boa forma de colocar à prova o algoritmo genético, com o objetivo de gerar o melhor agente possível para desempenhar as tarefas pretendidas. Contudo, só seria possível desenvolver um agente completamente capaz de desempenhar as tarefas de uma forma profissional após milhares ou milhões de gerações.

Referências

<https://web.fe.up.pt/~ee98221/paginas/algo.htm>

https://en.wikipedia.org/wiki/Genetic_algorithm

[https://en.wikipedia.org/wiki/Mutation_\(genetic_algorithm\)](https://en.wikipedia.org/wiki/Mutation_(genetic_algorithm))

[https://en.wikipedia.org/wiki/Crossover_\(genetic_algorithm\)](https://en.wikipedia.org/wiki/Crossover_(genetic_algorithm))

[https://www.researchgate.net/post/It is normal to have crossover probability much smaller than mutation probability](https://www.researchgate.net/post/It_is_normal_to_have_crossover_probability_much_smaller_than_mutation_probability)

<https://towardsdatascience.com/introduction-to-genetic-algorithms-including-example-code-e396e98d8bf3>